

TRABAJO DE FIN DE MÁSTER

Data Science & IA

Sistema inteligente de predicción de demanda para taxistas autónomos

Transferencia de modelos de Nueva York a Terrassa y producto funcional para
un caso real

Autor: Pau Gavilán

2026

Resumen

Este trabajo desarrolla un sistema de predicción de demanda y apoyo a la decisión para taxistas autónomos, orientado a un caso de uso real en la ciudad de Terrassa. El problema central es la ausencia de datos públicos de viajes de taxi a nivel local: para resolverlo se entrena un modelo de predicción espacio-temporal sobre el conjunto de datos abierto de taxis de Nueva York (NYC TLC) y se transfiere a Terrassa apoyándose en las matrices de movilidad del Ministerio de Transportes y en datos reales registrados por una taxista en activo. La comparativa de modelos muestra que un modelo de gradient boosting (LightGBM) reduce el error porcentual (WAPE) del 28,5 % de un baseline ingenuo al 16,5 %, superando claramente a un modelo clásico de series temporales (Prophet). La transferencia se valida cuantitativamente: la forma horaria de la demanda presenta una correlación de 0,88 entre ambos contextos, lo que respalda la hipótesis de que el patrón temporal se transfiere mientras que la escala se recalibra con datos locales. El resultado se materializa en una aplicación funcional y desplegada que recomienda paradas, registra carreras mediante el reconocimiento de tickets por fotografía y muestra la rentabilidad real del usuario.

Palabras clave: predicción de demanda, modelado espacio-temporal, transferencia de modelos, gradient boosting, movilidad urbana, taxi.

Abstract

This work develops a demand-forecasting and decision-support system for self-employed taxi drivers, applied to a real use case in the city of Terrassa (Spain). The core problem is the absence of public taxi-trip data at local level: to address it, a spatio-temporal forecasting model is trained on the open New York City taxi dataset (NYC TLC) and transferred to Terrassa using the mobility matrices published by the Spanish Ministry of Transport, together with real trip records logged by an active taxi driver. The model comparison shows that a gradient-boosting model (LightGBM) reduces the weighted absolute percentage error (WAPE) from 28.5 % for a naive baseline to 16.5 %, clearly outperforming a classical time-series model (Prophet). The transfer is validated quantitatively: the hourly shape of demand correlates at $r = 0.88$ between both contexts, supporting the hypothesis that the temporal pattern transfers while the scale must be recalibrated with local data. The outcome is a functional, deployed application that recommends taxi ranks, logs trips through photo-based ticket recognition and reports the driver's real profitability.

Keywords: demand forecasting, spatio-temporal modelling, transfer learning, gradient boosting, urban mobility, taxi.

Índice

Resumen.....	2
Abstract	2
Índice.....	3
Índice de figuras.....	5
Índice de tablas	5
1 Introducción	6
1.1 Motivación	6
1.2 Objetivos.....	6
1.3 Alcance y estructura del documento	6
2 Contexto y estado del arte.....	7
2.1 Predicción de demanda espacio-temporal	7
2.2 El conjunto de datos de Nueva York y la ausencia de datos locales	7
2.3 Transferencia de modelos entre contextos	7
3 Datos.....	7
3.1 Datos de taxi de Nueva York (NYC TLC)	7
3.2 Movilidad local: estudio de movilidad del MITMA	8
3.3 Variables externas	8
3.4 Datos reales del taxista	8
3.5 Protección de datos y consideraciones éticas	8
4 Análisis exploratorio de la demanda	9
4.1 Dispersión: la demanda es mayoritariamente cero	9
4.2 El ritmo diario	10
4.3 El ritmo semanal.....	10
4.4 La dimensión espacial	12
4.5 Estabilidad a lo largo del año	14
4.6 Síntesis	14
5 Metodología y modelado	14
5.1 Definición del problema	14
5.2 Ingeniería de variables	14
5.3 Horizonte de predicción.....	15
5.4 Validación temporal y métricas.....	15
5.5 Modelo de referencia (baseline)	15

5.6	Comparativa de modelos	15
5.7	Discusión de resultados.....	17
6	Transferencia de Nueva York a Terrassa.....	18
6.1	Hipótesis.....	18
6.2	Perfil de movilidad de Terrassa	18
6.3	Comparación de patrones.....	19
6.4	Limitaciones de la fuente local	21
6.5	Limitaciones de resolución espacial.....	21
7	Producto: la aplicación	22
7.1	Definición del producto y del usuario.....	22
7.2	Arquitectura	22
7.3	Alcance real de la integración	22
7.4	Funcionalidades.....	23
7.5	Captura de datos por fotografía	23
7.6	Despliegue.....	23
8	Conclusiones y trabajo futuro	23
8.1	Conclusiones	23
8.2	Limitaciones.....	24
8.3	Líneas futuras	24
9	Bibliografía.....	25
10	Anexos	26
10.1	Anexo A — Consentimiento informado.....	26
10.2	Anexo B — Plantilla de registro de carreras	26
10.3	Anexo C — Capturas de la aplicación	27
10.4	Anexo D — Estructura del repositorio	27

Índice de figuras

Figura 1. Distribución de la demanda por zona-hora, recortada al percentil 99. El 61,5 % de las celdas de la rejilla registra cero recogidas.	9
Figura 1. Demanda media por hora del día. El valle nocturno y el pico vespertino son la señal temporal dominante.....	10
Figura 1. Demanda media por día de la semana.	11
Figura 1. Curva horaria en días laborables frente a fines de semana. El fin de semana no desplaza la curva: le cambia la forma.....	11
Figura 1. Demanda media cruzando hora del día y día de la semana.	12
Figura 1. Quince zonas con mayor demanda acumulada en 2023.	13
Figura 1. Demanda media por zona (quince principales) y hora del día. Cada zona tiene su propia hora punta.	13
Figura 1. Demanda diaria total agregada de Nueva York durante 2023.....	14
Figura 1. Importancia de variables de LightGBM, medida como número de divisiones del árbol en que interviene cada una.....	18
Figura 1. Movilidad media de Terrassa por distrito y hora del día (fuente: MITMA).....	19
Figura 1. Perfiles horario y semanal agregados de la movilidad de Terrassa.....	19
Figura 1. Forma horaria normalizada de ambos contextos. La correlación de 0,88 sostiene la hipótesis de transferencia del patrón temporal.....	20
Figura 1. Forma semanal normalizada de ambos contextos.....	21

Índice de tablas

Tabla 1. Resultados sobre todas las zonas (conjunto de prueba, noviembre–diciembre). ...	16
Tabla 1. Comparación equitativa sobre la muestra de las 30 zonas de mayor demanda.....	16
Tabla 1. Hiperparámetros del modelo LightGBM de producción.	17
Tabla 1. Campos de la plantilla de registro de carreras.....	27
Tabla 1. Organización del repositorio del proyecto.	28

1 Introducción

1.1 Motivación

El sector del taxi tradicional afronta una competencia creciente por parte de las plataformas de vehículos con conductor, que disponen de sistemas sofisticados de predicción de demanda y asignación. Frente a ellas, el taxista autónomo opera en gran medida con intuición y experiencia, sin herramientas analíticas que le ayuden a decidir dónde y cuándo posicionarse. El presente trabajo nace de un caso concreto y cercano —una taxista autónoma en activo en Terrassa— con un objetivo doble: reducir el tiempo de circulación sin pasaje (kilómetros en vacío) y aportar al conductor información clara sobre su propia rentabilidad.

La motivación no es únicamente técnica. Se busca construir un producto que una persona sin conocimientos de informática pueda utilizar en su día a día, lo que sitúa el foco tanto en la calidad de los modelos como en la experiencia de uso.

1.2 Objetivos

Construir un modelo de predicción de demanda de taxi a nivel espacio-temporal (zona y franja horaria) y comparar de forma rigurosa distintas familias de modelos con métricas cuantitativas.

Resolver la ausencia de datos locales mediante la transferencia de patrones desde un conjunto de datos abundante (Nueva York) al contexto de Terrassa, validando dicha transferencia con fuentes locales.

Desarrollar un producto funcional y desplegado, usable por un conductor real, que recomiende dónde posicionarse y registre la actividad de forma sencilla.

Establecer un mecanismo de captura de datos reales que permita validar y, en el futuro, calibrar localmente el sistema.

1.3 Alcance y estructura del documento

El capítulo 2 sitúa el trabajo en su contexto. El capítulo 3 describe las fuentes de datos. El capítulo 4 presenta el análisis exploratorio de la demanda, que fundamenta las decisiones de modelado. El capítulo 5 detalla la metodología y la comparativa de modelos. El capítulo 6 aborda la transferencia de Nueva York a Terrassa, elemento diferenciador del proyecto. El capítulo 7 presenta el producto desarrollado y su arquitectura. El capítulo 8 recoge las conclusiones y las líneas de trabajo futuro.

Conviene delimitar el alcance desde el principio, porque condiciona la lectura de todo el documento. El trabajo comprende dos mitades que no están todavía unidas. La primera es un modelo de demanda entrenado y evaluado sobre datos reales de Nueva York, con una comparativa cuantitativa de modelos. La segunda es un prototipo de producto desplegado y en uso para Terrassa, cuya recomendación se calcula hoy a partir del perfil de movilidad local y no de la inferencia del modelo entrenado. La unión efectiva de ambas —la transferencia operativa— requiere un volumen de datos locales que aún se está acumulando, y se documenta como línea futura en el apartado 8.3.

2 Contexto y estado del arte

2.1 Predicción de demanda espacio-temporal

La predicción de demanda de movilidad es un área activa de investigación. El problema consiste en estimar el número de servicios que se originarán en cada zona geográfica y franja temporal, a partir de patrones históricos y de variables de contexto como el clima, los festivos o los eventos. Se trata de un problema de regresión con una fuerte componente estacional (diaria y semanal) y espacial.

El estado del arte abarca desde modelos clásicos de series temporales hasta enfoques de aprendizaje profundo. [Ampliar con referencias bibliográficas concretas del estado del arte]

2.2 El conjunto de datos de Nueva York y la ausencia de datos locales

La Taxi and Limousine Commission de Nueva York (NYC TLC) publica de forma abierta los registros de viajes de taxi, con millones de servicios documentados por mes e identificados por zona de recogida. Esta abundancia contrasta con la situación local: no existe un conjunto público equivalente de viajes de taxi en Terrassa ni en Barcelona. Los portales de datos abiertos solo ofrecen paradas estáticas y agregados del sector, no viajes individuales. Esta carencia es precisamente el reto metodológico que estructura el proyecto.

2.3 Transferencia de modelos entre contextos

Cuando un modelo se entrena con datos de un contexto y se aplica a otro distinto, su rendimiento no está garantizado: un modelo entrenado con datos de Manhattan no predice directamente la demanda de una ciudad media como Terrassa. La estrategia adoptada distingue entre lo que se transfiere —la forma de los patrones temporales— y lo que debe recalibrarse —la escala y la geografía locales—, apoyándose en fuentes de movilidad locales para la recalibración.

3 Datos

3.1 Datos de taxi de Nueva York (NYC TLC)

Se utilizan los registros de Yellow Taxi de 2023 en formato Parquet. A partir de los viajes individuales se construye una tabla de demanda agregada por zona de recogida, fecha y hora. Un aspecto metodológico clave es el relleno de ceros: toda combinación de zona y hora sin viajes se representa explícitamente como demanda cero, no como dato ausente; de lo contrario el modelo no aprendería cuándo la demanda es nula. La rejilla resultante contiene 2.303.880 filas (zona $\times$ fecha $\times$ hora), procedentes de 38,3 millones de viajes repartidos en 263 zonas.

La agregación se resuelve con DuckDB, lo que permite recorrer los doce ficheros mensuales —unos 620 MB en total— y construir la rejilla completa sin cargar los viajes individuales en memoria.

3.2 Movilidad local: estudio de movilidad del MITMA

Como aproximación a la demanda local se emplea el Estudio de la movilidad con Big Data del Ministerio de Transportes y Movilidad Sostenible, que ofrece matrices origen-destino por hora y distrito censal a partir de datos anonimizados de telefonía móvil, en cumplimiento de la normativa de protección de datos. Se extrae una muestra representativa (una semana por trimestre de 2023) para los siete distritos de Terrassa. Conviene subrayar que esta fuente mide movilidad general, no demanda de taxi: actúa como proxy, una limitación que se documenta de forma explícita.

3.3 Variables externas

Se incorporan variables meteorológicas de la API de Open-Meteo y el calendario de festivos, por su influencia conocida sobre la demanda de movilidad.

3.4 Datos reales del taxista

La validación final y el caso de uso se apoyan en los datos reales de carreras de una taxista de Terrassa (cooperativa Tele-Taxi Egara). Cada ticket aporta fecha, horas de inicio y fin, direcciones de origen y destino, distancia, importe y tipo de servicio. Estos datos se capturan mediante el reconocimiento automático de la fotografía del ticket, descrito en el capítulo 7.

3.5 Protección de datos y consideraciones éticas

El tratamiento de datos personales de este trabajo se limita a los registros de carreras aportados voluntariamente por una única conductora, y se realiza conforme al Reglamento (UE) 2016/679 (RGPD) y a la Ley Orgánica 3/2018.

La base legal es el consentimiento explícito e informado de la interesada, recogido por escrito antes del inicio de la recogida (anexo A). La finalidad es exclusivamente académica: el desarrollo y la evaluación de este Trabajo de Fin de Máster. El consentimiento es revocable en cualquier momento, sin necesidad de justificación y con supresión de los datos ya recogidos.

En cuanto a la minimización, el registro no recoge ningún dato identificativo de los clientes: ni nombre, ni teléfono, ni matrícula, ni forma de pago nominativa. Sí recoge, en cambio, direcciones de origen y destino de los servicios, que constituyen un dato personal indirecto en la medida en que podrían contribuir a identificar a un tercero. Por ese motivo las direcciones no se publican, no se incluyen en los anexos y no salen del entorno de trabajo del autor; los análisis que aparecen en la memoria se realizan siempre sobre agregados.

El punto que requiere mayor cautela es el reconocimiento automático de tickets descrito en el apartado 7.4. La fotografía del ticket se envía a la API de Gemini (Google), que actúa por tanto como encargado del tratamiento y que implica una transferencia internacional de datos. La conductora fue informada expresamente de esta circunstancia antes de aceptar el uso de la herramienta. Los datos extraídos se almacenan en una hoja de cálculo de acceso restringido, y las credenciales de acceso se mantienen fuera del control de versiones del

proyecto. Una versión de producción del sistema debería sustituir este componente por un reconocimiento óptico ejecutado en local, lo que eliminaría por completo la transferencia a un tercero; se recoge como línea futura.

Finalmente, el conjunto de datos de Nueva York es de publicación abierta y ya se distribuye agregado y sin identificadores personales, y las matrices del MITMA se publican anonimizadas y agregadas por el propio Ministerio, de modo que ninguna de las dos fuentes plantea un tratamiento adicional.

4 Análisis exploratorio de la demanda

Antes de modelar conviene entender la estructura de los datos, porque son sus propiedades —y no una preferencia a priori— las que justifican las decisiones metodológicas del capítulo 5: qué variables construir, qué métrica usar y qué función objetivo resulta apropiada. Este capítulo recorre la rejilla de demanda de Nueva York descrita en el apartado 3.1.

4.1 Dispersión: la demanda es mayoritariamente cero

El primer hecho relevante es la dispersión de la matriz. De los 2.303.880 pares zona-hora del año, el 61,5 % registra cero recogidas. La mediana de la demanda es 0 y la media 16,6, lo que refleja una distribución fuertemente asimétrica: unas pocas zonas concentran volúmenes muy altos mientras la mayoría permanece inactiva buena parte del día.



Figura 1. Distribución de la demanda por zona-hora, recortada al percentil 99. El 61,5 % de las celdas de la rejilla registra cero recogidas.

Esta observación tiene dos consecuencias directas sobre el modelado. La primera afecta a la métrica: el error porcentual absoluto medio (MAPE) exige dividir por el valor real, de modo que con una mayoría de ceros se vuelve indefinido o desproporcionado; se adopta en su lugar el WAPE, que pondera por el volumen total y es estable ante ceros. La segunda afecta a

la función objetivo: se trata de un problema de conteo, no negativo y con exceso de ceros, para el que un objetivo de tipo Poisson resulta más adecuado que el error cuadrático habitual.

4.2 El ritmo diario

La señal temporal más fuerte es la hora del día. La curva presenta un valle profundo entre las tres y las cinco de la madrugada, un ascenso sostenido durante la mañana y un máximo claro en la franja vespertina, alrededor de las seis de la tarde.




Figura 2. Demanda media por hora del día. El valle nocturno y el pico vespertino son la señal temporal dominante.

Que la hora sea la variable más informativa justifica su codificación cíclica mediante seno y coseno, que se describe en el apartado 5.2: sin ella, un modelo trataría las 23:00 y las 00:00 como valores extremos y distantes, cuando en realidad son contiguas.

4.3 El ritmo semanal

El día de la semana introduce una segunda estacionalidad, de menor amplitud pero sistemática. La actividad crece de forma progresiva a lo largo de la semana laboral y alcanza su máximo el viernes y el sábado.




Figura 3. Demanda media por día de la semana.

Más informativo que el nivel medio es el cambio de forma. Al separar los días laborables de los fines de semana, las dos curvas horarias no se diferencian por una simple traslación vertical: el fin de semana desplaza actividad desde la hora punta de la mañana hacia la madrugada, lo que refleja un uso de ocio frente a un uso de desplazamiento al trabajo. Este cambio de forma —y no solo de escala— es lo que justifica incorporar un indicador de fin de semana como variable del modelo.




Figura 4. Curva horaria en días laborables frente a fines de semana. El fin de semana no desplaza la curva: le cambia la forma.

La interacción conjunta de ambas estacionalidades se aprecia mejor en el mapa de calor de hora por día de la semana, donde se distinguen con nitidez la hora punta laborable y la actividad nocturna del viernes y el sábado.




Figura 5. Demanda media cruzando hora del día y día de la semana.

4.4 La dimensión espacial

La demanda se concentra de forma muy desigual en el territorio. Las quince zonas más activas acumulan una fracción desproporcionada del total anual, encabezadas por los distritos centrales de Manhattan y los aeropuertos.




Figura 6. Quince zonas con mayor demanda acumulada en 2023.

Ahora bien, el dato verdaderamente relevante para el producto no es qué zona acumula más demanda, sino que cada zona tiene su propio perfil horario. Los aeropuertos presentan picos ligados a las oleadas de llegadas; las zonas de oficinas se activan en las horas punta laborales; las zonas de ocio nocturno concentran su actividad de madrugada. Esta heterogeneidad espacio-temporal es exactamente la información que un sistema de recomendación debe explotar: no basta con saber cuándo hay demanda, hay que saber dónde a cada hora.




Figura 7. Demanda media por zona (quince principales) y hora del día. Cada zona tiene su propia hora punta.

4.5 Estabilidad a lo largo del año

La serie diaria agregada se mantiene razonablemente estable durante 2023, sin tendencia marcada, con una estacionalidad semanal visible y con caídas puntuales coincidentes con festivos y episodios meteorológicos adversos. La ausencia de una tendencia fuerte respalda el uso de un único año de datos y la validez de una partición temporal en la que los dos últimos meses actúan como conjunto de prueba.




Figura 8. Demanda diaria total agregada de Nueva York durante 2023.

4.6 Síntesis

El análisis exploratorio deja cuatro conclusiones que condicionan el capítulo siguiente: la matriz es dispersa y obliga a elegir métrica y función objetivo con cuidado; la hora del día es la señal dominante y debe codificarse de forma cíclica; el día de la semana modifica la forma de la curva y no solo su nivel; y el comportamiento es fuertemente heterogéneo entre zonas, lo que exige un modelo capaz de aprender patrones distintos por zona en lugar de una curva única para toda la ciudad.

5 Metodología y modelado

5.1 Definición del problema

El objetivo de predicción no es un viaje aislado, sino el número de recogidas esperadas en cada par (zona, franja horaria). Se adopta una resolución horaria y la zonificación nativa del conjunto de Nueva York, trasladable conceptualmente a los distritos de Terrassa.

5.2 Ingeniería de variables

A partir de la tabla de demanda se construyen variables de calendario (hora, día de la semana, mes, indicador de fin de semana y de festivo), la codificación cíclica de la hora justificada en el apartado 4.2 y, sobre todo, variables de retardo (lags): la demanda de la misma zona una hora antes, veinticuatro horas antes y una semana antes (168 horas), junto con medias móviles de veinticuatro horas y de una semana. Estas variables de retardo

capturan la fuerte autocorrelación temporal de la demanda. El conjunto final consta de catorce variables.

5.3 Horizonte de predicción

Es necesario precisar el horizonte al que se evalúa el modelo, porque condiciona la interpretación de las métricas. Al incluir la demanda de la hora anterior entre las variables, el modelo se evalúa a un horizonte de una hora, disponiendo del valor real ya observado en el instante inmediatamente anterior. Es lo que en la literatura se denomina predicción a un paso.

Este planteamiento es coherente con el caso de uso —el conductor decide dónde posicionarse en la próxima hora, no la próxima semana— y con la disponibilidad de datos en un sistema en explotación, donde el histórico reciente se conoce. Pero conviene señalar sus límites: a horizontes mayores la variable de retardo de una hora deja de estar disponible y debería sustituirse por la propia predicción del modelo, lo que acumula error. Una evaluación a veinticuatro horas prescindiendo de esa variable arrojaría métricas necesariamente peores y queda planteada como trabajo futuro. Las cifras que se presentan a continuación deben leerse, por tanto, como el rendimiento a una hora vista, no como una capacidad predictiva a largo plazo.

5.4 Validación temporal y métricas

La evaluación se realiza con una partición temporal —no aleatoria—: se entrena con los meses de enero a octubre y se valida con noviembre y diciembre. Mezclar las observaciones al azar permitiría al modelo «ver el futuro» y produciría métricas falsamente optimistas. Se reportan el error absoluto medio (MAE), la raíz del error cuadrático medio (RMSE) y el error porcentual ponderado (WAPE). Se descarta deliberadamente el MAPE porque, con numerosas celdas de demanda cero, su cálculo se vuelve inestable.

La partición emplea un único corte temporal. Un esquema de validación cruzada de origen móvil, con varios cortes sucesivos, permitiría acompañar las métricas de un intervalo de confianza y descartar que los resultados dependan del bimestre concreto elegido. No se ha implementado por coste de cómputo y se recoge como limitación.

5.5 Modelo de referencia (baseline)

Como referencia se emplea un predictor ingenuo: la demanda de una zona y hora es igual a la de esa misma hora la semana anterior. Todo modelo debe superar este baseline para justificar su utilidad.

5.6 Comparativa de modelos

Se comparan tres familias: un modelo clásico de series temporales (Prophet), un modelo de gradient boosting (LightGBM, con objetivo de tipo Poisson, apropiado para conteos) y una red neuronal recurrente (LSTM). La tabla 1 recoge los resultados sobre el conjunto de prueba completo; la tabla 2 compara de forma equitativa los modelos sobre la muestra de las treinta zonas de mayor demanda, escala a la que es viable ajustar Prophet.

Modelo	MAE	RMSE	WAPE
Baseline (misma hora, semana anterior)	4,98	18,85	28,5 %
LightGBM (objetivo Poisson)	2,87	9,57	16,5 %

Tabla 1. Resultados sobre todas las zonas (conjunto de prueba, noviembre–diciembre).

Modelo	MAE	RMSE	WAPE
Baseline (muestra)	31,21	52,70	25,2 %
LightGBM (muestra)	16,95	26,58	13,7 %
Prophet (muestra)	42,77	63,23	34,5 %

Tabla 2. Comparación equitativa sobre la muestra de las 30 zonas de mayor demanda.

Los hiperparámetros de LightGBM se fijaron a valores habituales para problemas de conteo de este tamaño, sin una búsqueda sistemática; la tabla 3 los recoge para garantizar la reproducibilidad del resultado.

Hiperparámetro	Valor	Motivo
objective	poisson	Conteos no negativos con exceso de ceros
n_estimators	500	Suficiente sin sobreajustar con la tasa elegida
learning_rate	0,05	Tasa conservadora, compensada con más árboles
num_leaves	63	Capacidad media; limita el sobreajuste por zona
min_child_samples	50	Evita hojas sostenidas por muy pocas observaciones
subsample	0,8	Submuestreo de filas para reducir varianza
colsample_bytree	0,8	Submuestreo de variables por árbol

Hiperparámetro	Valor	Motivo
random_state	42	Reproducibilidad

Tabla 3. Hiperparámetros del modelo LightGBM de producción.

La familia LSTM quedó planteada pero su ejecución se pospone como trabajo futuro: la versión de Python del entorno de desarrollo (3.14) es posterior a las versiones para las que TensorFlow publica distribuciones, por lo que la librería no puede instalarse sin construir un entorno paralelo. El código del experimento está escrito y versionado; su ausencia no altera la conclusión principal del capítulo, dado que el modelo ganador supera al baseline con un margen amplio.

5.7 Discusión de resultados

LightGBM es el ganador con claridad: reduce el WAPE del 28,5 % del baseline al 16,5 %, casi a la mitad el MAE y a la mitad el RMSE. La fuerte caída del RMSE indica que el modelo acierta especialmente en los picos de demanda, donde el baseline falla y donde reside el valor para el usuario.

Un resultado igualmente informativo es que Prophet no supera siquiera al baseline en la muestra (34,5 % frente a 25,2 %). La razón es estructural y conviene explicitarla para no atribuir al modelo una debilidad que en realidad es de configuración: Prophet ajusta cada zona de forma aislada y, tal como se ha empleado aquí, no recibe ninguna variable exógena, mientras que LightGBM dispone de las variables de retardo y de la información cruzada entre zonas. La comparación no enfrenta, por tanto, dos modelos con la misma información de entrada; lo que demuestra es que, para este problema, la capacidad de explotar retardos y relaciones entre zonas pesa más que el modelado explícito de la estacionalidad. Ese hallazgo es precisamente lo que justifica la elección de LightGBM como modelo de producción.

El análisis de importancia de variables confirma esta lectura y añade un matiz. La variable con mayor número de divisiones es la zona, seguida de la hora del día y del retardo semanal.




Figura 9. Importancia de variables de LightGBM, medida como número de divisiones del árbol en que interviene cada una.

Conviene interpretar esta figura con cautela: la importancia por número de divisiones favorece de forma conocida a las variables categóricas de alta cardinalidad, y la zona toma 263 valores distintos, de modo que su primer puesto está en parte inducido por la propia métrica. Descontado ese efecto, la lectura es coherente con el análisis exploratorio del capítulo 4: la hora del día y el retardo de una semana son las dos señales temporales dominantes, seguidas de los retardos de una hora y de un día. Las variables de calendario de grano grueso —mes, día del mes y festivo— aportan poco, lo que resulta esperable en una serie sin tendencia anual marcada.

6 Transferencia de Nueva York a Terrassa

6.1 Hipótesis

La hipótesis de transferencia sostiene que la forma de la demanda —su ritmo a lo largo del día y de la semana— es un comportamiento de movilidad razonablemente común entre ciudades, mientras que la escala absoluta y la geografía son específicas de cada lugar. En consecuencia, el patrón aprendido en Nueva York puede transferirse a Terrassa, recalibrando la escala con fuentes locales.

6.2 Perfil de movilidad de Terrassa

A partir de las matrices del MITMA se construye un perfil local de movilidad: viajes por distrito, hora y día de la semana para los siete distritos de Terrassa. Este perfil aporta la dimensión espacial y temporal propia de la ciudad.




Figura 10. Movilidad media de Terrassa por distrito y hora del día (fuente: MITMA).




Figura 11. Perfiles horario y semanal agregados de la movilidad de Terrassa.

6.3 Comparación de patrones

Comparando los perfiles temporales normalizados de ambos contextos, la forma horaria presenta una correlación muy alta ($r = 0,88$): el valle de madrugada, la actividad sostenida durante el día y el pico vespertino son esencialmente comunes.




Figura 12. Forma horaria normalizada de ambos contextos. La correlación de 0,88 sostiene la hipótesis de transferencia del patrón temporal.

La superposición revela además dos diferencias sistemáticas que la correlación por sí sola no muestra y que conviene señalar. La primera es que Terrassa arranca antes y de forma más abrupta: entre las seis y las ocho de la mañana la actividad local se dispara mientras la de Nueva York asciende con suavidad, un reflejo del peso del desplazamiento al trabajo en una ciudad media con fuerte movilidad de entrada y salida. La segunda es que Nueva York mantiene una cola nocturna notablemente más alta, coherente con un servicio de taxi en una ciudad de actividad continua frente a la movilidad general de una ciudad de tamaño medio. Ambas diferencias apuntan a los tramos horarios donde una recalibración local sería más necesaria.

La forma semanal muestra una correlación también alta, aunque menor ($r = 0.73$), coherente con las diferencias estructurales entre un servicio de taxi —con mayor peso de la noche de fin de semana— y la movilidad general de una ciudad media.




Figura 13. Forma semanal normalizada de ambos contextos.

Estos resultados respaldan la estrategia adoptada: el patrón temporal se transfiere, la escala se recalibra.

6.4 Limitaciones de la fuente local

La principal limitación es que la fuente local mide movilidad general y no demanda de taxi, por lo que actúa como proxy. La calibración fina, zona a zona, requerirá un volumen suficiente de datos reales del taxista, que se acumulan de forma continua a través de la aplicación.

6.5 Limitaciones de resolución espacial

Existe una segunda limitación, de naturaleza distinta y con consecuencias directas sobre la calidad de la recomendación, que merece cuantificarse antes que enunciarse.

El perfil local tiene resolución de distrito y Terrassa se divide en siete, mientras que la ciudad cuenta con catorce paradas de taxi. Varias paradas caen necesariamente dentro del mismo distrito y comparten, por construcción, un valor de demanda idéntico: cuatro de ellas se sitúan en el distrito 01. El sistema puede por tanto ordenar distritos, pero no discriminar entre paradas de un mismo distrito.

Al descomponer la varianza del perfil de movilidad se obtiene que el distrito explica el 36,3 % de la variación, frente al 53,3 % que explica la combinación de hora y día de la semana. Dicho de otro modo, la componente temporal del perfil es más informativa que la espacial. A ello se añade que la señal espacial está en buena medida determinada por el tamaño de la población: la correlación entre los viajes totales de cada distrito y su número de habitantes es de 0,885, de manera que el ranking espacial reproduce en gran parte la distribución de población y no una intensidad de demanda de taxi por habitante.

La consecuencia práctica es que la recomendación espacial actual es de grano grueso y está sesgada hacia los distritos más poblados. Superarla no requiere más datos de la misma fuente, sino una fuente de mayor resolución o una ponderación de cada parada por sus

atractores de demanda —estaciones, hospitales, zonas de ocio—, línea que se recoge en el apartado 8.3.

7 Producto: la aplicación

7.1 Definición del producto y del usuario

El producto responde a una pregunta concreta del taxista autónomo: «¿dónde y cuándo me coloco para ganar más sin dar vueltas en vacío?». El usuario final no tiene conocimientos técnicos, lo que condiciona el diseño hacia una interfaz simple, pensada para un vistazo rápido y para su uso desde el teléfono móvil.

7.2 Arquitectura

El sistema se organiza en capas: adquisición de datos (NYC TLC, MITMA, Open-Meteo y registro del taxista), preprocesado, almacenamiento, modelado y, finalmente, la capa de presentación o inteligencia de negocio (BI), que es la única que ve el usuario. Esta separación garantiza que el dato crudo nunca se altera y que la complejidad técnica permanece oculta tras una interfaz sencilla.

El almacenamiento sigue una organización por capas de refinamiento: los ficheros originales descargados se conservan intactos, una segunda capa guarda la tabla de demanda agregada y una tercera la tabla de variables lista para el entrenamiento. Cualquiera de las dos últimas puede regenerarse por completo a partir de la primera ejecutando el proceso documentado en el repositorio.

7.3 Alcance real de la integración

Este apartado precisa qué parte del sistema descrito está efectivamente conectada, para evitar una lectura más optimista de la que corresponde.

El modelo de demanda del capítulo 5 está entrenado y evaluado sobre datos de Nueva York, pero no alimenta todavía la recomendación que muestra la aplicación. Lo que el modo Conductor calcula hoy es un índice de demanda derivado del perfil de movilidad local del MITMA, cruzado con la ubicación de las paradas: es decir, una consulta sobre el perfil local, no una inferencia del modelo entrenado.

La razón es la expuesta en los apartados 6.4 y 6.5: unir ambas mitades exige recalibrar la escala y la geografía con datos locales de demanda de taxi, y el volumen acumulado por el sistema de captura es todavía insuficiente para hacerlo con garantías. Se ha preferido dejar la transferencia operativa como línea futura documentada antes que cerrar el circuito con una calibración no validada, que produciría recomendaciones de fiabilidad desconocida presentadas al usuario con apariencia de predicción.

El trabajo entrega por tanto dos resultados verificables por separado —un modelo de demanda evaluado cuantitativamente y un producto desplegado y en uso— junto con la evidencia cuantitativa (capítulo 6) de que la unión entre ambos es plausible.

7.4 Funcionalidades

La aplicación, desarrollada con Streamlit, integra tres modos en una sola interfaz:

Conductor: recomienda la parada a la que dirigirse en cada momento y muestra un mapa interactivo de Terrassa con la demanda por zonas, expresada en niveles (alta, media, baja) en lugar de cifras, para no transmitir una precisión que el dato no tiene. Incorpora las catorce paradas de taxi reales de la ciudad, y contempla los festivos y la lluvia como factores de contexto.

Registrar: permite fotografiar el ticket de una carrera; un modelo de visión extrae automáticamente los datos, que el usuario revisa antes de guardarlos.

Análisis: muestra los patrones de demanda, la comparación de la transferencia y la rentabilidad real del conductor, leída en directo del registro de carreras.

Los niveles de demanda se asignan por terciles sobre los valores presentes en cada momento, y no mediante umbrales fijos. La razón es consecuencia directa de la limitación descrita en el apartado 6.5: con umbrales fijos sobre el máximo, ninguna parada alcanzaba nunca el nivel bajo, porque el único distrito de actividad reducida no contiene ninguna parada de taxi. El criterio por terciles se aplica sobre los valores distintos, de modo que dos paradas del mismo distrito reciben siempre la misma etiqueta.

7.5 Captura de datos por fotografía

Para minimizar la fricción del registro —principal riesgo para la continuidad de la recogida de datos— la aplicación incorpora un lector de tickets. La fotografía se procesa con un modelo de visión (Gemini), que devuelve los campos estructurados; el usuario los confirma o corrige, manteniendo a la persona en el bucle, y se almacenan en una hoja de cálculo en la nube (Google Sheets). De este modo, los datos registrados retroalimentan de inmediato las métricas de rentabilidad del propio usuario. Las implicaciones de protección de datos de este componente se analizan en el apartado 3.5.

7.6 Despliegue

La aplicación se despliega en Streamlit Community Cloud y es accesible desde el navegador del teléfono, donde puede añadirse a la pantalla de inicio como una aplicación. El usuario no necesita instalar nada: completa un servicio, fotografía el ticket y el dato queda guardado.

8 Conclusiones y trabajo futuro

8.1 Conclusiones

El trabajo demuestra que es posible construir un sistema de apoyo a la decisión útil para un taxista autónomo a pesar de la ausencia de datos locales de viajes. La comparativa de modelos arroja un ganador claro y cuantificado —LightGBM reduce el WAPE del 28,5 % del baseline al 16,5 %, un 42 % menos de error—, la hipótesis de transferencia se valida con una correlación de 0,88 en la forma horaria, y el resultado se materializa en un producto real, desplegado y usable por una persona sin perfil técnico.

Igual de relevante es el mecanismo de captura de datos: al reducir el registro de una carrera a fotografiar un ticket, el sistema genera de forma continua el conjunto de datos local que hoy no existe y que es la condición necesaria para cerrar la transferencia.

8.2 Limitaciones

Las limitaciones se han ido señalando en cada capítulo; conviene recogerlas juntas.

La fuente de movilidad local mide movilidad general y no demanda de taxi: actúa como proxy (apartado 6.4).

La resolución espacial es de distrito, con siete distritos para catorce paradas, y la señal espacial correlaciona a 0,885 con la población, de modo que la recomendación espacial es de grano grueso y está sesgada hacia los distritos más poblados (apartado 6.5).

El modelo se evalúa a un horizonte de una hora, disponiendo del valor observado inmediatamente anterior; no se ha medido su rendimiento a horizontes mayores (apartado 5.3).

La validación emplea un único corte temporal, sin validación cruzada de origen móvil ni intervalos de confianza (apartado 5.4).

La comparativa queda incompleta: el LSTM está implementado pero no ejecutado por incompatibilidad de versiones del entorno (apartado 5.6).

El modelo entrenado no alimenta todavía la recomendación del producto (apartado 7.3).

El volumen de datos reales del taxista es aún reducido y está en proceso de acumulación, por lo que no ha sido posible una validación local del sistema.

Conviene asimismo señalar que una eventual adopción masiva de la herramienta por muchos conductores podría saturar las zonas recomendadas, un efecto de conocimiento común que queda fuera del alcance de este trabajo pero que cualquier despliegue real debería considerar.

8.3 Líneas futuras

Cerrar la transferencia operativa: aplicar el patrón temporal aprendido en Nueva York a las paradas de Terrassa, recalibrado con el volumen local, de modo que la recomendación pase a apoyarse en el modelo entrenado.

Elevar la resolución espacial ponderando cada parada por sus atractores de demanda — estaciones, hospitales, centros sanitarios y zonas de ocio— en lugar de repartir de forma uniforme el valor del distrito.

Evaluar el modelo a veinticuatro horas vista, sin la variable de retardo de una hora, para caracterizar su rendimiento a horizontes largos.

Completar la comparativa con el modelo LSTM en un entorno con una versión de Python compatible con TensorFlow.

Incorporar un esquema de validación cruzada de origen móvil que permita acompañar las métricas de intervalos de confianza.

Sustituir el reconocimiento de tickets en la nube por un reconocimiento óptico local, eliminando la transferencia de datos a un tercero.

Incorporar funciones de personalización («tus mejores horas y zonas») y un mecanismo de retorno del usuario sobre el acierto de las recomendaciones, que permitiría medir por primera vez la calidad del recomendador.

Escalar el sistema de un autónomo a cooperativas o pequeñas flotas, y evolucionar la interfaz hacia una aplicación nativa.

9 Bibliografía

NYC Taxi and Limousine Commission. TLC Trip Record Data. Disponible en el portal de datos abiertos de la ciudad de Nueva York.

Ministerio de Transportes y Movilidad Sostenible. Estudio de la movilidad con Big Data. Open Data Movilidad.

Open-Meteo. Free Weather API.

Kotov, E. et al. spanishoddata: A package for accessing Spanish Open Mobility Big Data.

[Añadir referencias del estado del arte y de la metodología (modelos de predicción de demanda, gradient boosting, etc.)]

10 Anexos

10.1 Anexo A — Consentimiento informado

Se reproduce a continuación el modelo de consentimiento entregado a la participante.
[Revisar con el tutor antes de la entrega y adjuntar el ejemplar firmado.]

Título del trabajo: Sistema inteligente de predicción de demanda para taxistas autónomos.
Responsable del tratamiento: Pau Gavilán, autor del Trabajo de Fin de Máster.

Finalidad. Los datos de las carreras que usted registre se utilizarán exclusivamente para el desarrollo y la evaluación de este Trabajo de Fin de Máster, con fines académicos y sin explotación comercial.

Datos recogidos. Fecha, hora de inicio y fin, direcciones de origen y destino, distancia, importe y tipo de servicio de cada carrera. No se recoge ningún dato identificativo de los clientes.

Tratamiento por terceros. La fotografía del ticket se procesa mediante la API de Gemini (Google), que actúa como encargado del tratamiento, lo que supone una transferencia internacional de datos. Los datos extraídos se almacenan en una hoja de cálculo de acceso restringido.

Publicación. En la memoria y en cualquier difusión del trabajo solo aparecerán datos agregados. Las direcciones concretas no se publicarán en ningún caso.

Conservación. Los datos se conservarán hasta la defensa del trabajo y su posterior evaluación, tras lo cual serán suprimidos.

Derechos. Puede retirar su consentimiento en cualquier momento, sin justificación y sin consecuencia alguna, y ejercer los derechos de acceso, rectificación, supresión, limitación, portabilidad y oposición dirigiéndose al responsable del tratamiento.

Nombre y apellidos: _____ DNI: _____

Firma: _____ Fecha: _____

10.2 Anexo B — Plantilla de registro de carreras

El registro se articula en una hoja de cálculo con tres pestañas: instrucciones de cumplimentación, registro de carreras y lista de zonas de referencia. La tabla 4 recoge los campos del registro.

Campo	Tipo	Obligatorio
Fecha	Fecha	Sí
Hora de recogida	Hora	Sí
Hora de fin	Hora	No
Zona de recogida	Texto	Sí
Zona de destino	Texto	No
Distancia (km)	Numérico	Sí
Importe (€)	Numérico	Sí

Campo	Tipo	Obligatorio
Origen del servicio	Texto	No
Forma de pago	Texto	No
Minutos en vacío antes	Númérico	No
Notas	Texto	No

Tabla 4. Campos de la plantilla de registro de carreras.

La hoja de instrucciones incluye la regla de oro entregada a la participante: anotar lo sucedido sin modificarlo a posteriori, y corregir mediante una nota en lugar de borrar, para preservar el valor del dato original.

10.3 Anexo C — Capturas de la aplicación

[Insertar aquí las capturas de los tres modos de la aplicación: Conductor con el mapa y el ranking de paradas, Registrar con el lector de tickets, y Análisis con las métricas de rentabilidad y la comparación de la transferencia.]

10.4 Anexo D — Estructura del repositorio

El código del proyecto se organiza del siguiente modo:

Ruta	Contenido
app.py	Aplicación Streamlit (punto de entrada del despliegue)
pipeline/	Fases 1 y 2: descarga y agregación, variables, baseline y modelos
notebooks/	Análisis exploratorio y comparación de patrones
scripts/	Utilidades: paradas de OpenStreetMap, geocodificación, lector de tickets
data/external/	Fuentes de terceros versionadas: perfil MITMA, distritos, paradas
data/raw · processed · gold	Capas de datos, regenerables desde la fase 1
results/	Tablas de resultados de la comparativa
docs/figuras/	Figuras de esta memoria y el script que las genera

Tabla 5. Organización del repositorio del proyecto.